

ENSTA



IP PARIS



**ÉCOLE NATIONALE D'INGÉNIEURS DE TUNIS
ÉCOLE NATIONALE SUPÉRIEURE DES TECHNIQUES
AVANCÉES**

STA 201

Projet Statistique

Réalisé par :

RAYEN ZARGUI

Classe :

2^{ÈME} ANNÉE TECHNIQUE AVANCÉE

Majeure :

MATHÉMATIQUES APPLIQUÉES

Encadré par :

MME ANISSA RABHI



Année universitaire 2024/2025

Table des matières

1 Analyse descriptive et visuelle	3
1.1 Aquisition des données	3
1.2 Analyse des données	4
1.2.1 Analyse descriptive de l'ensemble de données <code>mtcars</code>	4
1.2.2 Nuage des points	5
1.2.3 Histogrammes	6
1.2.4 Corrélation	8
1.2.5 Boxplot	10
2 Régression multiple	11
2.1 Modèle initial	11
2.2 Modèle par selection	12
2.3 Comparaison des deux modèles linéaires	12
2.4 Ajout au jeu de données	13
2.4.1 Modèle complet	14
2.4.2 Modèle réduit	14
2.4.3 Impact sur la regression	14
3 Analyse en composantes principales	16
3.0.1 Valeurs propres et variance expliquée	16
3.0.2 Cercle des corrélations	18
3.0.3 Contributions des variables	19
3.0.4 Projection des individus	21
3.0.5 Régression sur les Composantes Principales	22
3.1 Test d'Anova	24
3.2 Interprétation Statistique	24
3.2.1 Comparaison des R ²	24
3.2.2 Test ANOVA	24
4 Comparaison des approches : régression classique vs régression sur ACP	25
4.1 Régression avec les variables d'origine	25
4.2 Régression sur les composantes principales (ACP)	25
4.3 Conclusion	25
4.3.1 Analyse exploratoire visuelle	27
4.3.2 Normalité des variables actives	28
4.4 Régression linéaire classique	28

4.4.1	Modèle complet et modèle sélectionné	28
4.5	Régression sur composantes principales (PCA)	29
4.5.1	Analyse en composantes principales	29
4.5.2	Visualisations	29
4.5.3	Régression sur les composantes principales	30
4.5.4	Comparaison des modèles	30

Table des figures

1.1	Code pour importer les données	3
1.2	Les données	3
1.3	Représentation descriptive des données	4
1.4	Nuage des points	5
1.5	Code utilisé	6
1.6	Les histogrammes	7
1.7	Matrice de corrélation	8
1.8	Corrplot	9
1.9	Boxplot	10
2.1	Summary du modèle linéaire	11
2.2	Summary du modèle par selection	12
2.3	Résidus en fonction des valeurs	13
2.4	Summary de modèle complet	14
2.5	Summary de modèle réduit	14
3.1	Valeurs propres et variance cumulée	16
3.2	Éboulis des valeurs propres (Scree plot)	17
3.3	Cercle des corrélations des variables	18
3.4	Contributions à la première composante	19
3.5	Contributions à la deuxième composante	20
3.6	Projection des véhicules colorés par cylindres	21
3.7	Projection des véhicules colorés par cylindres	22
3.8	summary du regression de ACP	23
3.9	Projection des véhicules colorés par cylindres	24

Introduction

L'objectif de cette analyse est d'étudier la consommation de carburant des véhicules en utilisant des données techniques telles que la cylindrée, la puissance, le poids ou encore le type de transmission comme variables explicatives. Pour ce faire, j'utiliserais le logiciel R afin de mener à bien l'analyse statistique.

Ma démarche consistera tout d'abord à explorer les statistiques descriptives des différentes variables pour dégager des tendances générales et visualiser les distributions. Ensuite, je réaliserais une analyse en composantes principales (ACP) afin de réduire la dimension du jeu de données et d'explorer les relations entre les variables et les observations.

Enfin, une régression linéaire multiple sera menée dans le but d'identifier les facteurs les plus influents sur la consommation de carburant. Une comparaison entre différents modèles, avec ou sans sélection de variables, ainsi que l'ajout d'une nouvelle observation, permettra d'analyser la robustesse et l'interprétation du modèle. L'utilisation conjointe de l'ACP et de la régression sur les composantes principales permettra également de souligner les avantages et les limites de chaque méthode dans le cadre de cette étude.

Chapitre 1

Analyse descriptive et visuelle

1.1 Aquisition des données

Dans un premier temps, j'ai importé le jeu de données à partir d'un fichier CSV, et je l'ai stocké dans l'objet **mtcars**, qui servira de base à l'ensemble de l'analyse. Ensuite, j'ai extrait les variables pertinentes pour l'étude et les ai organisées au sein de sous-ensembles distincts afin de faciliter les différentes étapes de traitement statistique, telles que l'analyse descriptive, l'ACP et la régression multiple.

```
# Chargement des données
mtcars <- read_csv("mtcars.csv")
data("mtcars")
```

FIGURE 1.1 – Code pour importer les données

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225	105	2.76	3.460	20.22	1	0	3	1

FIGURE 1.2 – Les données

L'ensemble de données mtcars comprend 32 observations et 11 variables. Parmi celles-ci, deux variables sont binaires : **am** (type de transmission, manuel ou automatique) et **vs** (type de moteur, en V ou droit). Trois variables sont discrètes : **gear** (nombre de vitesses), **carb** (nombre de carburateurs) et **cyl** (nombre de cylindres). Les six autres variables, à savoir **mpg** (consommation de carburant), **disp** (cylindrée), **hp** (chevaux), **drat** (rapport d'essieu arrière), **wt** (poids) et **qsec** (temps pour 1/4 de mile), présentent une distribution continue.

1.2 Analyse des données

1.2.1 Analyse descriptive de l'ensemble de données `mtcars`

J'ai entamé l'analyse des données en calculant plusieurs statistiques descriptives pour chacune des variables. Ces mesures incluent le minimum, le maximum, le premier quartile, la médiane, le troisième quartile ainsi que la moyenne. Ces valeurs ont été obtenues à l'aide de la fonction `summary`.

```
> summary(mtcars)
```

	mpg	cyl	disp	hp	drat
Min.	10.40	Min. :4.000	Min. : 71.1	Min. : 52.0	Min. :2.760
1st Qu.	15.43	1st Qu.:4.000	1st Qu.:120.8	1st Qu.: 96.5	1st Qu.:3.080
Median	19.20	Median :6.000	Median :196.3	Median :123.0	Median :3.695
Mean	20.09	Mean :6.188	Mean :230.7	Mean :146.7	Mean :3.597
3rd Qu.	22.80	3rd Qu.:8.000	3rd Qu.:326.0	3rd Qu.:180.0	3rd Qu.:3.920
Max.	33.90	Max. :8.000	Max. :472.0	Max. :335.0	Max. :4.930
	wt	qsec	vs	am	
Min.	1.513	Min. :14.50	Min. :0.0000	Min. :0.0000	
1st Qu.	2.581	1st Qu.:16.89	1st Qu.:0.0000	1st Qu.:0.0000	
Median	3.325	Median :17.71	Median :0.0000	Median :0.0000	
Mean	3.217	Mean :17.85	Mean :0.4375	Mean :0.4062	
3rd Qu.	3.610	3rd Qu.:18.90	3rd Qu.:1.0000	3rd Qu.:1.0000	
Max.	5.424	Max. :22.90	Max. :1.0000	Max. :1.0000	
	gear	carb			
Min.	3.000	Min. :1.000			
1st Qu.	3.000	1st Qu.:2.000			
Median	4.000	Median :2.000			
Mean	3.688	Mean :2.812			
3rd Qu.	4.000	3rd Qu.:4.000			
Max.	5.000	Max. :8.000			

FIGURE 1.3 – Représentation descriptive des données

Interprétation : Les statistiques descriptives de l'ensemble de données `mtcars` révèlent des informations clés sur les 11 variables étudiées, représentant 32 modèles de voitures.

La variable `mpg` (consommation de carburant) varie de 10,4 à 33,9 miles par gallon, avec une médiane de 19,2 et une moyenne de 20,09. Cela indique une distribution légèrement asymétrique à droite, où la majorité des voitures ont une consommation modérée, mais quelques modèles sont très économies.

Les variables continues telles que `disp` (cylindrée) et `hp` (puissance en chevaux) présentent une grande variabilité, avec des valeurs allant respectivement de 71,1 à 472 et de 52 à 335. Leurs médianes (196,3 pour `disp` et 123 pour `hp`) sont inférieures aux moyennes (230,7 et 146,7), suggérant une asymétrie à droite due à quelques véhicules très puissants.

Le poids (`wt`) varie de 1,513 à 5,424, avec une médiane de 3,325. Cela signifie que la moitié des voitures pèsent moins de 3,325 unités, mais quelques modèles très lourds tirent la moyenne vers le haut (3,217). La variable `qsec` (temps pour le quart de mile) présente une distribution plus symétrique, allant de 14,5 à 22,9, avec une médiane de 17,71 proche de la moyenne (17,85).

Concernant les variables discrètes, `cyl` (nombre de cylindres) montre que la majorité des voitures possèdent 4, 6 ou 8 cylindres, avec une médiane de 6, ce qui

réfère une prédominance de moteurs de taille moyenne à grande. La variable **gear** (nombre de vitesses) indique une répartition entre 3, 4 et 5 vitesses, avec une médiane de 4. La variable **carb** (nombre de carburateurs) varie de 1 à 8, mais la médiane est de 2, suggérant que les voitures avec 1 ou 2 carburateurs sont les plus courantes.

Enfin, les variables binaires **am** (type de transmission) et **vs** (type de moteur) présentent une répartition équilibrée. Pour **am**, la médiane est 0 (transmission automatique), mais le troisième quartile est à 1, ce qui indique que 40,6 % des voitures ont une transmission manuelle. Quant à **vs**, la médiane est également 0 (moteur en ligne), avec 43,75 % des voitures équipées d'un moteur en V.

Ces données illustrent une diversité dans les caractéristiques des voitures, avec des tendances marquées : les voitures plus lourdes et plus puissantes tendent à consommer davantage de carburant, tandis que les modèles plus légers et équipés de transmissions manuelles sont généralement plus économies. Ces observations préliminaires orientent les analyses ultérieures, notamment sur l'impact de variables telles que le poids et la puissance sur la consommation de carburant.

1.2.2 Nuage des points

En utilisant la fonction ‘pairs’, j’ai obtenu le nuage de points de mes données pour explorer les relations entre les différentes variables.




FIGURE 1.4 – Nuage des points

Consommation de carburant (mpg) : La variable mpg, représentant la consommation en miles par gallon, montre des corrélations notables avec plusieurs autres variables :

- Une **corrélation négative marquée** avec le poids (**wt**) : les voitures plus lourdes consomment davantage de carburant.
- Des **corrélations négatives** également observées avec la cylindrée (**disp**) et la puissance (**hp**), ce qui indique que les voitures plus puissantes ou avec un moteur de plus grande capacité tendent à être moins économies.
- Une **corrélation légèrement positive** avec le temps au quart de mile (**qsec**), suggérant que les voitures moins performantes sur le plan de l'accélération sont souvent plus économies.
- Une association avec la transmission (**am**) : les véhicules à transmission manuelle (**am = 1**) tendent à avoir une consommation plus faible.

Corrélations entre variables techniques :

- Une **forte corrélation positive** est observée entre la cylindrée (**disp**) et la puissance (**hp**).
- Le poids (**wt**) est positivement corrélé à la puissance et à la cylindrée, ce qui est cohérent avec des véhicules plus massifs ayant besoin de moteurs plus puissants.

Variables discrètes : Les variables **cyl** (nombre de cylindres), **gear** (nombre de vitesses), **carb** (nombre de carburateurs), **am** (type de transmission) et **vs** (type de moteur) affichent des regroupements visibles sous forme de bandes, typiques des variables catégorielles ou discrètes. Ces regroupements mettent en évidence certaines configurations mécaniques dominantes :

- La majorité des véhicules ont 4, 6 ou 8 cylindres.
- Les transmissions manuelles sont davantage associées à des voitures à 4 ou 5 vitesses.

1.2.3 Histogrammes

Code

```
# Histogrammes des variables
plot_list <- list()
for (i in 1:ncol(mtcars)) {
  plot_list[[i]] <- ggplot(mtcars, aes(x = .data[[names(mtcars)[i]]])) +
    geom_histogram(fill = colors[i %% length(colors) + 1], color = "white", bins = 10, alpha = 0.8) +
    labs(title = paste("Distribution de", names(mtcars)[i]),
         x = names(mtcars)[i],
         y = "Fréquence") +
    theme_minimal() +
    theme(plot.title = element_text(size = 10))
}
grid.arrange(grobs = plot_list, ncol = 3)
```

FIGURE 1.5 – Code utilisé




FIGURE 1.6 – Les histogrammes

Interprétation

L’analyse des histogrammes des 11 variables de l’ensemble de données `mtcars` met en évidence les tendances générales et les formes de distribution suivantes :

- **mpg (consommation de carburant)** : la distribution est légèrement asymétrique à droite, avec une majorité de valeurs comprises entre 15 et 25 miles par gallon. Quelques observations atteignent 30 à 35 mpg, correspondant à des véhicules particulièrement économies.
- **cyl (nombre de cylindres)** : la variable est discrète, avec trois niveaux dominants (4, 6 et 8 cylindres). On observe une forte représentation des moteurs à 4 et 8 cylindres, traduisant une polarisation entre véhicules économiques et puissants.
- **disp (cylindrée)** : la distribution est fortement asymétrique à droite. La plupart des observations se situent entre 100 et 200, mais certaines atteignent jusqu’à 500, indiquant la présence de moteurs très volumineux.
- **hp (puissance)** : cette variable suit une distribution similaire à celle de la cylindrée, avec un regroupement entre 50 et 200 chevaux. Quelques modèles très puissants dépassent les 300 chevaux.
- **drat (rapport de pont)** : la distribution est bimodale, avec deux pics autour de 3,0 et 4,0. Cela pourrait refléter deux types de conception de véhicules, l’un favorisant l’accélération, l’autre l’efficacité énergétique.
- **wt (poids)** : la distribution est légèrement asymétrique à droite, avec un pic autour de 3,0 à 3,5. Certaines voitures très lourdes dépassent 5,0, indiquant une hétérogénéité dans les caractéristiques structurelles.
- **qsec (temps pour parcourir 1/4 de mile)** : cette variable présente une distribution relativement symétrique, centrée autour de 17 à 18 secondes.

Quelques valeurs extrêmes sont observées entre 14 et 23 secondes.

- **vs (type de moteur)** : variable binaire (0 = moteur en V, 1 = moteur en ligne), la répartition est presque équilibrée avec une légère majorité de moteurs en V.
- **am (type de transmission)** : cette variable binaire montre une dominance des transmissions automatiques (0), avec environ 40% de transmissions manuelles (1).
- **gear (nombre de vitesses)** : la distribution discrète est concentrée autour de 3 et 4 vitesses. Les véhicules à 5 vitesses sont minoritaires, souvent associés à des modèles sportifs ou récents.
- **carb (nombre de carburateurs)** : la distribution est asymétrique avec un pic à 2 carburateurs. Certains modèles atteignent jusqu'à 8 carburateurs, généralement liés à des performances élevées.

1.2.4 Corrélation

En utilisant la fonction **cor**, j'ai obtenu la matrice de corrélation qui donne la corrélation entre les différentes variables.

	mpg	cyl	disp	hp	drat	wt	qsec	vs
mpg	1.0000000	-0.8521620	-0.8475514	-0.7761684	0.68117191	-0.8676594	0.41868403	0.6640389
cyl	-0.8521620	1.0000000	0.9020329	0.8324475	-0.69993811	0.7824958	-0.59124207	-0.8108118
disp	-0.8475514	0.9020329	1.0000000	0.7909486	-0.71021393	0.8879799	-0.43369788	-0.7104159
hp	-0.7761684	0.8324475	0.7909486	1.0000000	-0.44875912	0.6587479	-0.70822339	-0.7230967
drat	0.6811719	-0.6999381	-0.7102139	-0.4487591	1.00000000	-0.7124406	0.09120476	0.4402785
wt	-0.8676594	0.7824958	0.8879799	0.6587479	-0.71244065	1.0000000	-0.17471588	-0.5549157
qsec	0.4186840	-0.5912421	-0.4336979	-0.7082234	0.09120476	-0.1747159	1.00000000	0.7445354
vs	0.6640389	-0.8108118	-0.7104159	-0.7230967	0.44027846	-0.5549157	0.74453544	1.0000000
am	0.5998324	-0.5226070	-0.5912270	-0.2432043	0.71271113	-0.6924953	-0.22986086	0.1683451
gear	0.4802848	-0.4926866	-0.5555692	-0.1257043	0.69961013	-0.5832870	-0.21268223	0.2060233
carb	-0.5509251	0.5269883	0.3949769	0.7498125	-0.09078980	0.4276059	-0.65624923	-0.5696071
	am	gear	carb					
mpg	0.59983243	0.4802848	-0.55092507					
cyl	-0.52260705	-0.4926866	0.52698829					
disp	-0.59122704	-0.5555692	0.39497686					
hp	-0.24320426	-0.1257043	0.74981247					
drat	0.71271113	0.6996101	-0.09078980					
wt	-0.69249526	-0.5832870	0.42760594					
qsec	-0.22986086	-0.2126822	-0.65624923					
vs	0.16834512	0.2060233	-0.56960714					
am	1.00000000	0.7940588	0.05753435					
gear	0.79405876	1.0000000	0.27407284					
carb	0.05753435	0.2740728	1.00000000					

FIGURE 1.7 – Matrice de corrélation

Et la fonction **corrplot** pour visualiser la corrélation entre les variables :




FIGURE 1.8 – Corrplot

Interprétation : La matrice de corrélation des variables de l’ensemble `mtcars` met en évidence plusieurs relations significatives entre les caractéristiques techniques des véhicules. La consommation de carburant (`mpg`) présente des corrélations négatives marquées avec le poids (`wt`, $r = -0,87$), la cylindrée (`disp`, $r = -0,85$), la puissance (`hp`, $r = -0,78$) et le nombre de cylindres (`cyl`, $r = -0,85$). Cela confirme que les véhicules plus lourds, puissants ou dotés de moteurs volumineux sont généralement moins économies.

En revanche, `mpg` est positivement corrélée avec le rapport de démultiplication final (`drat`, $r = 0,68$) ainsi qu’avec le type de transmission (`am`, $r = 0,60$), suggérant que des rapports d’essieux plus élevés et les transmissions manuelles contribuent à une meilleure efficacité énergétique.

Par ailleurs, les variables liées à la puissance et à la taille du moteur – `cyl`, `disp`, `hp` et `wt` – sont fortement interconnectées, avec des coefficients de corrélation allant de 0,79 à 0,90, traduisant leur interdépendance dans la conception des véhicules. Enfin, le temps au quart de mile (`qsec`) est modérément corrélé négativement avec la puissance (`hp`, $r = -0,71$), ce qui indique que les voitures plus puissantes tendent

à être plus rapides à l'accélération.

1.2.5 Boxplot

```
1 boxplot(mtcars, main = "Boxplots des variables de mtcars",
          col = "lightblue", las = 2)
```

Listing 1.1 – Boxplot des variables du jeu mtcars




FIGURE 1.9 – Boxplot

Chapitre 2

Régression multiple

2.1 Modèle initial

```
1 full_model <- lm(mpg ~ cyl + disp + hp + drat + wt + qsec +
  vs + am + gear + carb, data = mtcars)
```

Listing 2.1 – Modèle de régression linéaire multiple ajusté sur `mtcars`

Le modèle initial est une régression linéaire multiple qui vise à expliquer la variable `mpg` (consommation de carburant) à partir de plusieurs caractéristiques techniques du véhicule. Il inclut des variables telles que le nombre de cylindres (`cyl`), la cylindrée (`disp`), la puissance (`hp`), le poids (`wt`), le type de transmission (`am`), ainsi que d'autres variables.

```
> summary(full_model)

Call:
lm(formula = mpg ~ cyl + disp + hp + drat + wt + qsec + vs +
  am + gear + carb, data = mtcars)

Residuals:
    Min      1Q  Median      3Q     Max 
-3.4506 -1.6044 -0.1196  1.2193  4.6271 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 12.30337  18.71788  0.657   0.5181    
cyl        -0.11144  1.04502 -0.107   0.9161    
disp        0.01334  0.01786  0.747   0.4635    
hp         -0.02148  0.02177 -0.987   0.3350    
drat        0.78711  1.63537  0.481   0.6353    
wt        -3.71530  1.89441 -1.961   0.0633 .  
qsec        0.82104  0.73084  1.123   0.2739    
vs          0.31776  2.10451  0.151   0.8814    
am          2.52023  2.05665  1.225   0.2340    
gear        0.65541  1.49326  0.439   0.6652    
carb       -0.19942  0.82875 -0.241   0.8122    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.65 on 21 degrees of freedom
Multiple R-squared:  0.869,    Adjusted R-squared:  0.8066 
F-statistic: 13.93 on 10 and 21 DF,  p-value: 3.793e-07
```

FIGURE 2.1 – Summary du modèle linéaire

2.2 Modèle par selection

```
1 modele_selection <- stepAIC(full_model, direction = "both",
  trace = FALSE)
```

Listing 2.2 – Sélection du modèle par la méthode stepwise (AIC)

Une sélection de variables a été réalisée à l'aide de la méthode pas à pas selon le critère d'Akaike (AIC). Le modèle initial incluait toutes les variables disponibles, mais la sélection a conduit à un modèle plus simple ne retenant que trois variables significatives : le poids du véhicule (wt), le temps sur 1/4 mile (qsec), et le type de transmission (am). Ce modèle réduit améliore la lisibilité tout en conservant une bonne capacité explicative, ce qui en fait un choix pertinent pour prédire la consommation de carburant.

```
> summary(modele_selection)

Call:
lm(formula = mpg ~ wt + qsec + am, data = mtcars)

Residuals:
    Min      1Q  Median      3Q     Max 
-3.4811 -1.5555 -0.7257  1.4110  4.6610 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 9.6178    6.9596   1.382 0.177915  
wt          -3.9165   0.7112  -5.507 6.95e-06 *** 
qsec         1.2259   0.2887   4.247 0.000216 *** 
am           2.9358   1.4109   2.081 0.046716 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.459 on 28 degrees of freedom
Multiple R-squared:  0.8497,    Adjusted R-squared:  0.8336 
F-statistic: 52.75 on 3 and 28 DF,  p-value: 1.21e-11
```

FIGURE 2.2 – Summary du modèle par selection

2.3 Comparaison des deux modèles linéaires

Deux modèles de régression multiple ont été construits pour étudier les facteurs influençant la consommation de carburant (`mpg`). Le premier modèle inclut l'ensemble des variables explicatives disponibles dans le jeu de données, tandis que le second a été obtenu par une procédure de sélection afin de ne conserver que les variables les plus pertinentes.

Modèle	R ² ajusté	Variables retenues
Modèle complet	0,869	cyl, disp, hp, drat, wt, qsec, vs, am, gear, carb
Modèle sélectionné	0,8497	wt, qsec, am

TABLE 2.1 – Comparaison des performances des deux modèles de régression

Le modèle réduit, bien que plus simple, présente un R² ajusté supérieur à celui du modèle complet, ce qui témoigne d'une meilleure capacité explicative avec un

nombre restreint de variables. Les variables conservées (`wt`, `qsec`, `am`) sont donc les plus influentes sur la consommation de carburant. Ce modèle est également plus facile à interpréter et plus adapté à une analyse pratique.




FIGURE 2.3 – Résidus en fonction des valeurs

2.4 Ajout au jeu de données

On fait l'ajout de cette voiture :

```
1 nouveau_vehicule <- data.frame( mpg = 35, cyl = 4, disp = 95,
    hp = 80, drat = 4.1, wt = 2.0, qsec = 18.5, vs = 1, am =
    1, gear = 5, carb = 1)
```

Listing 2.3 – Création d'un nouveau véhicule avec des caractéristiques spécifiques

2.4.1 Modèle complet

```
> summary(modele_complet_ajout)

Call:
lm(formula = mpg ~ ., data = mtcars_ajout)

Residuals:
    Min      1Q  Median      3Q     Max 
-4.5308 -1.5788 -0.0716  1.3848  4.8971 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 7.38249   20.06726   0.368   0.716    
cyl          0.22034   1.11649   0.197   0.845    
disp         0.01017   0.01922   0.529   0.602    
hp          -0.02080   0.02351  -0.885   0.386    
drat         0.68854   1.76571   0.390   0.700    
wt          -3.10237   2.02311  -1.533   0.139    
qsec         0.74738   0.78854   0.948   0.354    
vs           0.67097   2.26625   0.296   0.770    
am           2.45247   2.22117   1.104   0.281    
gear         1.94186   1.47908   1.313   0.203    
carb        -0.74046   0.85330  -0.868   0.395    

Residual standard error: 2.863 on 22 degrees of freedom
Multiple R-squared:  0.8656, Adjusted R-squared:  0.8046 
F-statistic: 14.17 on 10 and 22 DF,  p-value: 2.082e-07
```

FIGURE 2.4 – Summary de modèle complet

2.4.2 Modèle réduit

```
> summary(modele_reduit_ajout)

Call:
lm(formula = mpg ~ wt + qsec + am, data = mtcars_ajout)

Residuals:
    Min      1Q  Median      3Q     Max 
-4.1045 -1.7014 -0.5203  1.4748  6.9485 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 8.8895    7.8280   1.136  0.265423  
wt          -4.0275    0.7993  -5.039 2.28e-05 ***  
qsec         1.2889    0.3240   3.978 0.000425 ***  
am           3.3715    1.5793   2.135  0.041350 *  
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1 

Residual standard error: 2.767 on 29 degrees of freedom
Multiple R-squared:  0.8345, Adjusted R-squared:  0.8173 
F-statistic: 48.73 on 3 and 29 DF,  p-value: 1.914e-11
```

FIGURE 2.5 – Summary de modèle réduit

2.4.3 Impact sur la regression

Afin d'évaluer la robustesse du modèle, une nouvelle observation représentant un véhicule léger, peu puissant mais très économique a été ajoutée artificiellement au jeu de données. Après réestimation, on observe une légère modification des coefficients du modèle, notamment une réduction de l'effet du poids (**wt**) sur la consommation.

Ce nouveau point a une forte consommation spécifique et un faible poids, ce qui tend à renforcer le lien inverse entre `wt` et `mpg`. Toutefois, les résidus indiquent que cette observation reste dans des limites raisonnables et ne déstabilise pas le modèle de manière excessive.

Chapitre 3

Analyse en composantes principales

L'analyse en composantes principales a été réalisée sur l'ensemble des variables quantitatives du jeu de données mtcars :

```
1 # Variables quantitatives completes
2 vars_quant <- c("mpg", "cyl", "disp", "hp", "drat", "wt", "
  qsec", "vs", "am", "gear", "carb")
3 data_acp <- mtcars[, vars_quant]
4
5 # ACP avec centrage-reduction
6 res_pca <- PCA(data_acp, scale.unit = TRUE, graph = FALSE)
```

Listing 3.1 – Code R pour l'ACP complète

3.0.1 Valeurs propres et variance expliquée

	eigenvalue	percentage of variance	cumulative percentage of variance
comp 1	6.60840025	60.0763659	60.07637
comp 2	2.65046789	24.0951627	84.17153
comp 3	0.62719727	5.7017934	89.87332
comp 4	0.26959744	2.4508858	92.32421
comp 5	0.22345110	2.0313737	94.35558
comp 6	0.21159612	1.9236011	96.27918
comp 7	0.13526199	1.2296544	97.50884
comp 8	0.12290143	1.1172858	98.62612
comp 9	0.07704665	0.7004241	99.32655
comp 10	0.05203544	0.4730495	99.79960
comp 11	0.02204441	0.2004037	100.00000
>			

FIGURE 3.1 – Valeurs propres et variance cumulée




FIGURE 3.2 – Éboulis des valeurs propres (Scree plot)

Le scree plot (Fig. 3.2) montre que :

- Les deux premières composantes capturent **84,2%** de la variance totale
 - Dim1 : 60,1%
 - Dim2 : 24,1%
- La troisième composante explique 5,7% de variance supplémentaire

3.0.2 Cercle des corrélations




FIGURE 3.3 – Cercle des corrélations des variables

L’analyse du cercle de corrélation (Fig. 3.3) révèle :

- **Axe 1** oppose :
 - Variables de puissance (hp, disp, cyl) à gauche
 - Variables d’efficacité (mpg, drat) à droite
- **Axe 2** sépare :
 - Variables d’accélération (qsec) en haut
 - Variables de transmission (am, gear) en bas

3.0.3 Contributions des variables




FIGURE 3.4 – Contributions à la première composante




FIGURE 3.5 – Contributions à la deuxième composante

Les figures 3.4 et 3.5 montrent que :

TABLE 3.1 – Principales contributions

Composante	Variables majeures	Contribution
Dim1	cyl, disp	> 15% chacune
Dim2	qsec, am, gear	> 10% chacune

3.0.4 Projection des individus




FIGURE 3.6 – Projection des véhicules colorés par cylindres

La projection (Fig. 3.9) montre une séparation nette selon le nombre de cylindres :

- **4 cylindres** : regroupés à droite (haute efficacité)
- **8 cylindres** : à gauche (haute puissance)
- **6 cylindres** : position intermédiaire

3.0.5 Régression sur les Composantes Principales




FIGURE 3.7 – Projection des véhicules colorés par cylindres

Les graphiques de diagnostic du modèle de régression multiple ajusté sur l'ensemble de données `mtcars` permettent d'évaluer la validité des hypothèses du modèle.

Résidus vs Valeurs ajustées

Ce graphique montre les résidus standardisés en fonction des valeurs prédictives. Les points sont dispersés de manière relativement aléatoire autour de la ligne horizontale à zéro, sans motif clair, ce qui suggère que l'hypothèse de linéarité et d'homoscédasticité (variance constante des résidus) est raisonnablement respectée. Cependant, des points comme Pontiac Firebird, Toyota Corolla et Fiat 128 se distinguent avec des résidus élevés (positifs ou négatifs), indiquant que le modèle prédit moins bien pour ces observations.

Q-Q Résidus

Le graphique quantile-quantile compare la distribution des résidus standardisés à une distribution normale théorique. La plupart des points suivent la ligne diagonale,

ce qui indique que les résidus sont approximativement normaux, une hypothèse clé de la régression linéaire. Cependant, des écarts sont visibles aux extrémités (Toyota Corolla, Pontiac Firebird, Fiat 128), suggérant de légers écarts par rapport à la normalité pour ces observations, bien que cela reste acceptable pour un échantillon de petite taille (32 observations).

Échelle-Localisation

Ce graphique montre la racine carrée des résidus standardisés en fonction des valeurs ajustées, pour évaluer l'homoscédasticité. La dispersion des points reste relativement constante, bien que la ligne de tendance montre une légère augmentation pour les valeurs ajustées plus élevées. Les points éloignés comme Pontiac Firebird, Toyota Corolla et Fiat 128 confirment leur statut de résidus inhabituels, mais l'homoscédasticité est globalement satisfaite.

Résidus vs Effet de levier

Ce graphique identifie les observations influentes en combinant les résidus standardisés et l'effet de levier. La distance de Cook est indiquée par des lignes pointillées. Toyota Corolla et Fiat 128 ont un effet de levier modéré et des résidus élevés, mais leur distance de Cook reste faible, suggérant qu'elles ne sont pas excessivement influentes. Pontiac Firebird a également un résidu notable, mais son effet de levier est faible. Aucune observation ne semble avoir un impact disproportionné sur le modèle.

```
> summary(model_pcr)

Call:
lm(formula = mpg ~ PC1 + PC2, data = scores)

Residuals:
    Min      1Q  Median      3Q     Max 
-4.3611 -1.7263 -0.3322  1.3208  5.6763 

Coefficients:
            Estimate Std. Error t value Pr(>|t|)    
(Intercept) 20.0906    0.4591  43.760 < 2e-16 ***
PC1        -2.2813    0.1944 -11.738 1.55e-12 ***
PC2         0.1163    0.2866   0.406    0.688    
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 2.597 on 29 degrees of freedom
Multiple R-squared:  0.8263,    Adjusted R-squared:  0.8143 
F-statistic: 68.97 on 2 and 29 DF,  p-value: 9.493e-12
```

FIGURE 3.8 – summary du regression de ACP

3.1 Test d'Anova

Analysis of Variance Table

Analysis of Variance Table						
Model 1: mpg ~ PC1 + PC2		Model 2: mpg ~ cyl + disp + hp + drat + wt + qsec + vs + am + gear + carb				
		Res.Df	RSS	Df	Sum of Sq	F Pr(>F)
1		29	195.60			
2		21	147.49	8	48.11	0.8562 0.5665

FIGURE 3.9 – Projection des véhicules colorés par cylindres

3.2 Interprétation Statistique

3.2.1 Comparaison des R²

- La différence entre le R² du modèle ACP (**0,82**) et celui de la régression multiple (**0,83**) est **négligeable** (< 1%).
- Le **R² ajusté** favorise légèrement le modèle ACP (**0,81** contre **0,79** pour le modèle multiple), suggérant un possible *sur-ajustement* du modèle complet.

3.2.2 Test ANOVA

- p-value = **0,5665** > 0,05 ⇒ **Aucune différence significative** entre les modèles
- Le modèle ACP montre une performance **équivalente** au modèle complet malgré :
 - Une complexité réduite (2 composantes vs 10 variables)
 - L'absence de problèmes de multicolinéarité

Implications :

- La réduction de dimension par ACP **préserve l'information pertinente** tout en simplifiant l'analyse
- Le modèle complet n'apporte pas d'amélioration significative malgré sa complexité accrue
- Le choix peut se faire sur des critères pratiques :
 - **ACP** pour la visualisation et l'analyse des structures latentes
 - **Régression multiple** pour l'interprétation physique directe (quand la multicolinéarité est contrôlée)

Chapitre 4

Comparaison des approches : régression classique vs régression sur ACP

4.1 Régression avec les variables d'origine

Avantages :

- Interprétation directe des coefficients : chaque variable garde sa signification initiale.
- Analyse précise de l'effet de chaque prédicteur sur la variable réponse.
- Mise en œuvre simple et compréhensible.

Inconvénients :

- Risque de multicolinéarité, pouvant fausser les estimations.
- Modèle instable en présence de nombreuses variables.
- Risque de surapprentissage avec un échantillon réduit.

4.2 Régression sur les composantes principales (ACP)

Avantages :

- Réduction de la dimension tout en conservant l'information essentielle.
- Suppression de la multicolinéarité grâce à l'orthogonalité des composantes.
- Modèle plus stable et robuste en ne conservant que les composantes pertinentes.

Inconvénients :

- Perte d'interprétabilité : les composantes sont des combinaisons de variables.
- Nécessite une transformation préalable des données (centrage, réduction).
- Significativité statistique ne garantit pas une compréhension intuitive.

4.3 Conclusion

Le choix dépend des objectifs :

- **Régression classique** : adaptée si l’interprétation des variables est primordiale.
- **Régression sur ACP** : préférable pour un modèle prédictif robuste en cas de corrélations élevées entre variables.

Annexe

```
1 library(readr)
2 library(ggplot2)
3 library(gridExtra)
4 library(FactoMineR)
5 library(corrplot)
6 library(MASS)
7 library(pls)
```

Listing 4.1 – Chargement des packages

```
1 mtcars <- read_csv("mtcars.csv")
2 data("mtcars")
3 View(mtcars)
4 head(mtcars)
5 summary(mtcars)
6 str(mtcars)
7 dim(mtcars)
```

Listing 4.2 – Chargement et exploration des données

4.3.1 Analyse exploratoire visuelle

```
1 pairs(mtcars)
2 cor_matrix <- cor(mtcars)
3 corrplot(cor_matrix, method = "circle")
```

Listing 4.3 – Diagrammes de paires et corrélations

```
1 colors <- c("#1f77b4", "#ff7f0e", "#2ca02c", "#d62728", "#9467bd",
2           "#8c564b", "#e377c2", "#7f7f7f", "#bcbd22", "#17becf", "#aec7e8")
3 plot_list <- list()
4 for (i in 1:ncol(mtcars)) {
5   plot_list[[i]] <- ggplot(mtcars, aes(x = .data[[names(
6     mtcars)[i]]])) +
7     geom_histogram(fill = colors[i %% length(colors) + 1],
8                   color = "white", bins = 10, alpha = 0.8) +
9     labs(title = paste("Distribution de", names(mtcars)[i])) +
10 }
```

```

8     theme_minimal()
9 }
10 grid.arrange(grobs = plot_list, ncol = 3)

```

Listing 4.4 – Histogrammes par variable

```

1 boxplot(mtcars, main = "Boxplots des variables de mtcars",
          col = "lightblue", las = 2)

```

Listing 4.5 – Boxplot global

4.3.2 Normalité des variables actives

```

1 vars_actives <- c("mpg", "disp", "hp", "drat", "wt", "qsec")
2 data_active <- mtcars[, vars_actives]
3 shapiro_results <- lapply(data_active, shapiro.test)
4 for (i in 1:length(shapiro_results)) {
5   cat("Variable :", names(shapiro_results)[i], "\n")
6   cat("p-value : ", round(shapiro_results[[i]]$p.value, 4), "
      \n")
7   cat("Conclusion :", ifelse(shapiro_results[[i]]$p.value <
      0.05, "Non normale", "Normale"), "\n\n")
8 }

```

Listing 4.6 – Test de Shapiro-Wilk

4.4 Régression linéaire classique

4.4.1 Modèle complet et modèle sélectionné

```

1 full_model <- lm(mpg ~ cyl + disp + hp + drat + wt + qsec +
      vs + am + gear + carb, data = mtcars)
2 summary(full_model)
3
4 modele_selection <- stepAIC(full_model, direction = "both",
      trace = FALSE)
5 summary(modele_selection)

```

Listing 4.7 – Régression linéaire classique

```

1 par(mfrow = c(1, 2))
2 plot(full_model, which = 1, main = "Résidus du modèle
      complet")
3 plot(modele_selection, which = 1, main = "Résidus du modèle
      sélectionné")

```

Listing 4.8 – Comparaison graphique des résidus

```

1 nouveau_vehicule <- data.frame(
2   mpg = 35, cyl = 4, disp = 95, hp = 80, drat = 4.1,
3   wt = 2.0, qsec = 18.5, vs = 1, am = 1, gear = 5, carb = 1
4 )
5 mtcars_ajout <- rbind(mtcars, nouveau_vehicule)
6 modele_complet_ajout <- lm(mpg ~ ., data = mtcars_ajout)
7 modele_reduit_ajout <- lm(mpg ~ wt + qsec + am, data = mtcars
8   _ajout)
9 summary(modele_complet_ajout)
summary(modele_reduit_ajout)

```

Listing 4.9 – Ajout d'un nouveau véhicule

4.5 Régression sur composantes principales (PCA)

4.5.1 Analyse en composantes principales

```

1 acp_data <- scale(mtcars[, -1])
2 res_acp <- prcomp(acp_data, center = TRUE, scale. = TRUE)
3 summary(res_acp)

```

Listing 4.10 – Centrage et ACP

4.5.2 Visualisations

```

1 fviz_eig(res_acp, addlabels = TRUE, barfill = "#2E9FDF")
2 fviz_pca_var(res_acp, col.var = "contrib", gradient.cols = c(
  "#4E79A7", "#59A14F", "#E15759"))

```

Listing 4.11 – Scree Plot et cercle des corrélations

```

1 fviz_contrib(res_acp, choice = "var", axes = 1, fill = "#4
  E79A7")
2 fviz_contrib(res_acp, choice = "var", axes = 2, fill = "#59
  A14F")

```

Listing 4.12 – Contributions des variables

```

1 fviz_pca_ind(res_acp,
2               col.ind = as.factor(mtcars$cyl),
3               addEllipses = TRUE,
4               ellipse.type = "confidence")

```

Listing 4.13 – Projection des individus

4.5.3 Régression sur les composantes principales

```
1 scores <- as.data.frame(res_acp$x[, 1:2])
2 colnames(scores) <- c("PC1", "PC2")
3 scores$mpg <- mtcars$mpg
4 model_pcr <- lm(mpg ~ PC1 + PC2, data = scores)
5 summary(model_pcr)
```

Listing 4.14 – Modèle PCR

```
1 ggplot(scores, aes(x = PC1, y = mpg)) +
2   geom_point(aes(color = as.factor(mtcars$cyl))) +
3   geom_smooth(method = "lm", se = FALSE) +
4   labs(title = "R gression: mpg ~ PC1")
```

Listing 4.15 – Visualisation de la régression

```
1 par(mfrow = c(2, 2))
2 plot(model_pcr)
```

Listing 4.16 – Diagnostic du modèle PCR

4.5.4 Comparaison des modèles

```
1 anova(model_pcr, full_model)
```

Listing 4.17 – Test ANOVA entre PCR et régression classique